HOCHSCHULE FULDA
UNIVERSITY OF APPLIED SCIENCES

Fachartikel – Seminar Gesundheitstechnik

Sommersemester 2026

KI-Bildanalyse in Industrie und Medizin:

Modelltraining und Inhouse-Architekturen

vorgelegt von:

Luca Michael Schmidt

Betreut von:

Prof. Dr. Martine Herpers

Hochschule Fulda – Fachbereich Angewandte Informatik

5. Mai 2026

Zusammenfassung

Industrielle KI-Bildanalyse und medizinische Diagnostik beruhen auf identischen methodischen Grundlagen. Am Beispiel des Defekterkennungssystems *ROSI* der Grenzebach BSH GmbH und des Modells CheXNet der Stanford University wird gezeigt, dass Convolutional Neural Networks mit Transfer-Learning-Ansatz direkt auf medizinische Bildgebung übertragbar sind. CheXNet übertraf beim Erkennen von Pneumonie auf Röntgenaufnahmen den durchschnittlichen F1-Score praktizierender Radiologen (0,435 vs. 0,387) **chexnet2017**. Zur Bewertung des Nutzens werden standardisierte Metriken (Sensitivität, Spezifität, F1-Score, AUC-ROC) eingesetzt. Da medizinische Bilddaten besonders schutzwürdig sind (Art. 9 DSGVO), werden datenschutzkonforme Systemarchitekturen – insbesondere Federated Learning mit Differential Privacy – als Implementierungsoption analysiert **federatedLearning2022**.

Inhaltsverzeichnis

1 Einleitung

1.1 Problemstellung

Die Auswertung medizinischer Bilddaten – Röntgen, CT, MRT – ist zeit- und ressourcenintensiv. Die Diagnoseleistung ist von menschlichen Faktoren wie Arbeitsbelastung und Ermüdung abhängig. KI-gestützte Systeme können in klar abgegrenzten Aufgaben vergleichbare oder bessere Ergebnisse erzielen **chexnet2017**.

Im industriellen Umfeld sind entsprechende Verfahren produktiv etabliert: Das System *ROSI* der Grenzebach BSH GmbH erkennt Defekte auf Baustoffen automatisiert durch neuronale Netze. Die methodischen Grundlagen beider Domänen sind strukturell identisch – beide erkennen Anomalien in Bilddaten durch trainierte Mustererkennung.

1.2 Forschungsfrage

Der Artikel untersucht: (1) welche Verfahren dem Modelltraining medizinischer KI-Bildanalyse zugrunde liegen, (2) wie der Nutzen quantitativ messbar ist, und (3) welche Architektur eine DSGVO-konforme Implementierung ermöglicht.

2 Themenbeschreibung: KI-Bildanalyse in Industrie und Medizin

Convolutional Neural Networks (CNNs) sind die technische Grundlage moderner KI-Bildanalyse. Durch hierarchische Faltungsoperationen extrahieren sie räumliche Merkmale: Frühe Schichten erkennen Kanten und Texturen, tiefere Schichten kombinieren diese zu semantischen Strukturen wie Anomalien oder Defektmustern.

Transfer Learning ergänzt diesen Ansatz: Ein auf großen allgemeinen Datensätzen vortrainiertes Modell wird auf einem domänenspezifischen Zieldatensatz feinabgestimmt (Fine-Tuning). Da medizinische Bilddatensätze aufwändig zu annotieren sind, ist dieser Ansatz besonders relevant.

Das Stanford-Modell **CheXNet** demonstriert den Stand der Technik: Ein 121-schichtiges DenseNet wurde auf ChestX-ray14 trainiert – einem öffentlichen Datensatz des NIH mit über 100 000 annotierten Röntgenaufnahmen und 14 Krankheitsklassen. Das Modell erreicht in der Erkennung von Pneumonie eine Leistung, die den Durchschnitt praktizierender Radiologen übertrifft **chexnet2017**.

Die methodische Parallele zur industriellen CV ist direkt: Tabelle **??** zeigt die strukturellen Entsprechungen beider Domänen.

Tabelle 1: Struktureller Vergleich: Industrial CV vs. medizinische Bildanalyse

Aspekt	Industrial CV (ROSI)	Medizinische Bildanalyse
Eingabedaten	Kameraaufnahmen Baustoffe	Röntgen, CT, MRT
Anomalieklassen	Risse, Ablösungen, Einschlüsse	Tumore, Frakturen, Läsionen
Kernmethode	Segmentierung + Klassifikation	Segmentierung + Klassifikation
Ausgabe	Defekttyp + Regelentscheid	Befund + Diagnoseempfehlung

Quelle: Eigene Darstellung

3 Messverfahren

Der Nutzen KI-gestützter Systeme lässt sich durch standardisierte Klassifikationsmetriken quantitativ belegen. Im Sinne der SMART-Kriterien werden folgende Messgrößen eingesetzt:

- **Sensitivität (Recall):** Anteil korrekt erkannter positiver Fälle (z. B. erkannte Pneumonien / alle Pneumonien im Testdatensatz).
- **Spezifität:** Anteil korrekt erkannter negativer Fälle.
- **F1-Score:** Harmonisches Mittel aus Precision und Recall – relevant bei unausgewogener Klassenverteilung.
- **AUC-ROC:** Fläche unter der Receiver-Operating-Characteristic-Kurve; klassenunabhängiges Gesamtmaß der Klassifikationsleistung.

CheXNet wurde in einem direkten Benchmark gegen vier praktizierende Fachradiologen getestet. Der erzielte F1-Score von 0,435 übertrifft den menschlichen Durchschnitt von 0,387 statistisch signifikant – auf einem separaten Testset, das von den vier Radiologen manuell annotiert wurde **chexnet2017**. Die Überlegenheit erstreckt sich auf beide Dimensionen: Sowohl Sensitivität als auch Spezifität lagen über dem Radiologen-Durchschnitt.

Dieses Verfahren – direkter Vergleich Mensch vs. KI auf einem gemeinsamen Testdatensatz mit etablierten Metriken – gilt als Standardbenchmark in der medizinischen KI-Forschung und ist auf das Thema dieses Artikels unmittelbar übertragbar.

Eidesstattliche Erklärung

Hiermit versichere ich, die vorliegende Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt sowie die Zitate deutlich kenntlich gemacht zu haben.
Ich erkläre weiterhin, dass die vorliegende Arbeit in gleicher oder ähnlicher Form noch nicht im Rahmen eines anderen Prüfungsverfahrens eingereicht wurde.

Bad Hersfeld, den 5. Mai 2026 Luca Michael Schmidt