



FACHARTIKEL – SEMINAR GESUNDHEITSTECHNIK

Sommersemester 2026

Von der Produktion zur Diagnose: Was die Medizin von industrieller KI-Bildanalyse lernen kann

vorgelegt von:

Luca Michael Schmidt

Betreut von:

Prof. Dr. Martine Herpers

Hochschule Fulda – Fachbereich Angewandte Informatik

19. Mai 2026

Zusammenfassung

Industrielle Qualitätskontrollsysteme und medizinische Bilddiagnostik lösen strukturell identische Aufgaben: die Lokalisation und Klassifikation von Anomalien in Bilddaten durch trainierte neuronale Netze. Der vorliegende Artikel untersucht, inwieweit die in der industriellen Bildanalyse etablierten Verfahren – insbesondere Convolutional Neural Networks und Transfer Learning – auf die medizinische Bildgebung übertragbar sind. Als empirischer Beleg dient das Modell CheXNet der Stanford University, das bei der Pneumonieerkennung auf Röntgenaufnahmen den durchschnittlichen F1-Score praktizierender Radiologen statistisch signifikant übertraf (0,435 vs. 0,387) [1]. Der Einsatz von KI als ergänzender zweiter Leser steigert die Sensitivität um den Faktor 1,12 bei gleichzeitiger Reduktion des Befundungsaufwands um rund 44 % [2]. Zur Quantifizierung des Nutzens werden standardisierte Metriken (Sensitivität, Spezifität, F1-Score, AUC-ROC) eingesetzt. Da medizinische Bilddaten besondere Schutzwürdigkeit genießen (Art. 9 DSGVO) und diagnostische KI-Systeme dem EU AI Act als Hochrisiko-KI unterliegen, werden datenschutzkonforme Systemarchitekturen – insbesondere Federated Learning mit Differential Privacy sowie On-Premise-Infrastrukturen – als Implementierungsoptionen analysiert [3], [4].

Inhaltsverzeichnis

1	Einleitung	3
1.1	Problemstellung	3
1.2	Motivation: Methodischer Transfer aus der industriellen Bildanalyse	3
1.3	Forschungsfragen	3
2	Industrielle KI-Bildanalyse als methodisches Vorbild	4
2.1	Technische Grundlagen und industrielle Anwendung	4
2.2	Struktureller Vergleich beider Domänen	4
3	Transfer in die medizinische Diagnostik	5
3.1	Transfer Learning: Methodische Übertragung zwischen Domänen	5
3.2	CheXNet: Empirischer Beleg des Transfers	5
3.3	KI als „zweiter Leser“: Kombierter Einsatz von Mensch und System	5
4	Messbarkeit des Nutzens	6
4.1	Metriken zur Leistungsbewertung	6
4.2	KI im Vergleich zum Menschen	6
5	Datensouveränität und Systemarchitektur	7
5.1	Rechtliche Anforderungen im Gesundheitswesen	7
5.2	Cloud vs. On-Premise	7
5.3	Federated Learning als datenschutzkonformer Lernverbund	7
6	Fazit und Ausblick	8
6.1	Zusammenfassung	8
6.2	Ausblick	8
	Literaturverzeichnis	9

1 Einleitung

1.1 Problemstellung

Die radiologische Befundung gehört zu den ressourcenintensivsten Aufgaben im klinischen Alltag. Röntgenaufnahmen, CT- und MRT-Untersuchungen müssen von hochspezialisierten Fachärztinnen und Fachärzten analysiert und befundet werden – ein Prozess, der weder einfach skalierbar noch uneingeschränkt fehlertolerant ist. Das Untersuchungsvolumen ist in den vergangenen zehn Jahren um drei bis fünf Prozent jährlich gewachsen [5], während die Fachkräftebasis nicht proportional mitgewachsen ist: In Deutschland sind von 13.791 approbierten Fachärztinnen und Fachärzten für Radiologie lediglich 10.139 berufstätig [6].

Die Folgen dieser Überlastung sind messbar: Die normierte Arbeitslast zum Zeitpunkt diagnostischer Fehler im CT-Befund betrug im Schnitt 121 % des Normalwerts [7]; 44 % der männlichen und 65 % der weiblichen Radiologen berichten Burnout-Symptome [8]. Die Diagnoseleistung ist damit strukturell von Faktoren wie Arbeitsbelastung und Ermüdung abhängig.

1.2 Motivation: Methodischer Transfer aus der industriellen Bildanalyse

In der industriellen Qualitätskontrolle sind KI-gestützte Bildanalyzesysteme seit über einem Jahrzehnt produktiv im Einsatz. Die methodische Grundlage dieser Systeme – Convolutional Neural Networks, Transfer Learning, Bildsegmentierung und Klassifikation – beschreibt allgemeine Verfahren zur Anomalieerkennung in Bilddaten, die auf die medizinische Bildgebung übertragbar sind. Empirische Studien belegen, dass der Transfer in die medizinische Diagnostik zu Ergebnissen auf radiologischem Niveau führt [1]. Dieser Artikel untersucht die methodischen Grundlagen, Leistungsmetriken und Systemarchitekturen, die diesen Transfer ermöglichen.

1.3 Forschungsfragen

Der Artikel richtet sich an Studierende der Gesundheitstechnik mit technischem Grundverständnis und untersucht drei Forschungsfragen:

1. Welche technischen Verfahren der industriellen Bildanalyse sind auf die medizinische Diagnostik übertragbar?
2. Wie lässt sich der Nutzen KI-gestützter Systeme quantitativ messen und belegen?
3. Welche Systemarchitektur ermöglicht eine DSGVO-konforme Implementierung im Krankenhaus?

2 Industrielle KI-Bildanalyse als methodisches Vorbild

2.1 Technische Grundlagen und industrielle Anwendung

Convolutional Neural Networks (CNNs) bilden das Fundament moderner KI-Bildanalyse in Industrie und Medizin gleichermaßen. Durch hierarchische Faltungsoperationen extrahieren sie räumliche Merkmale: Frühe Schichten erfassen Kanten und Texturen, tiefere Schichten kombinieren diese zu semantischen Strukturen – etwa Defektmuster oder pathologische Veränderungen. Transfer Learning ergänzt diesen Ansatz: Ein auf einem großen allgemeinen Datensatz vortrainiertes Modell wird durch Fine-Tuning auf einem domänenspezifischen Zieldatensatz spezialisiert. Da sowohl industrielle als auch medizinische Bilddatensätze annotationsaufwändig und vergleichsweise klein sind, stellt dieser Ansatz in beiden Domänen die entscheidende Voraussetzung für Praxistauglichkeit dar [9].

In der industriellen Qualitätskontrolle sind CNN-basierte Systeme produktiv etabliert. Systeme zur automatisierten Erkennung von Materialfehlern auf Baustoffen kombinieren Bildsegmentierung zur Lokalisation des Defektbereichs mit Klassifikation zur Einordnung des Fehlertyps (z. B. Risse, Ablösungen, Fremdeinschlüsse). Die Ausgabe ist ein strukturierter Regelentscheid in Echtzeit, ohne menschliche Zwischeninstanz. Die zentralen Systemeigenschaften – Skalierbarkeit, Reproduzierbarkeit und Unabhängigkeit von individueller Ermüdung – sind genau jene, die der radiologischen Befundung unter wachsendem Ressourcendruck fehlen (vgl. Abschnitt 1.1).

2.2 Struktureller Vergleich beider Domänen

Tabelle 1 zeigt, dass industrielle Qualitätskontrolle und medizinische Bilddiagnostik strukturell identische Aufgaben lösen.

Tabelle 1: Struktureller Vergleich: Industrielle CV vs. medizinische Bildanalyse

Aspekt	Industrielle CV	Medizinische Bildanalyse
Eingabedaten	Kameraaufnahmen (Baustoffe, Produkte)	Röntgen, CT, MRT
Anomalieklassen	Risse, Ablösungen, Einschlüsse	Tumore, Frakturen, Läsionen
Kernmethode	Segmentierung + Klassifikation	Segmentierung + Klassifikation
Ausgabe	Defekttyp + Regelentscheid	Befund + Diagnoseempfehlung
Betriebsstatus	produktiv, skaliert, erprobt	in Einführung und Erprobung

Quelle: Eigene Darstellung

Die nachfolgenden Abschnitte untersuchen, wie dieser Transfer empirisch validiert wird und welche infrastrukturellen Voraussetzungen er im Gesundheitswesen erfordert.

3 Transfer in die medizinische Diagnostik

3.1 Transfer Learning: Methodische Übertragung zwischen Domänen

Transfer Learning ermöglicht die methodische Übertragung von Modellwissen zwischen Anwendungsdomänen. Ein auf einem großen allgemeinen Bilddatensatz vortrainiertes Modell verfügt über hierarchische Repräsentationen grundlegender Bildstrukturen – Kanten, Texturen, geometrische Formen. Diese Repräsentationen lassen sich durch gezieltes Fine-Tuning auf medizinische Bilddaten spezialisieren. Da medizinische Bildbestände annotationsaufwändig und im Vergleich zu allgemeinen Datensätzen deutlich kleiner sind, überbrückt dieser Ansatz den Datenmangel systematisch [9].

Aktuelle Forschungsergebnisse zeigen, dass eine Vortrainingsphase auf domänenverwandten Daten die Transferleistung weiter verbessert, da die Domänendistanz zum Zieldatensatz sinkt [10].

3.2 CheXNet: Empirischer Beleg des Transfers

Das Modell **CheXNet** der Stanford University demonstriert den realisierten Transfer exemplarisch. Ein 121-schichtiges DenseNet wurde auf ChestX-ray14 trainiert – einem öffentlichen Datensatz des National Institutes of Health (NIH) mit über 100.000 annotierten Röntgenaufnahmen und 14 Krankheitsklassen. Das Modell wurde anschließend in einem direkten Benchmark gegen vier praktizierende Fachradiologen evaluiert.

CheXNet erzielte bei der Erkennung von Pneumonie einen F1-Score von 0,435, gegenüber dem Radiologen-Durchschnitt von 0,387 – statistisch signifikant auf einem gemeinsamen, verblinden Testdatensatz [1]. Das Ergebnis belegt, dass CNN-Architekturen aus der industriellen Defekterkennung auf medizinischen Bilddaten Klassifikationsleistungen auf dem Niveau von Fachspezialisten erzielen.

3.3 KI als „zweiter Leser“: Kombiniertes Einsatz von Mensch und System

Das praktisch wirksamste Einsatzmodell ist nicht die vollständige Automatisierung der Befundung, sondern der Einsatz von KI als ergänzenden zweiten Leser: Das System übernimmt die Vorselektion, grenzwertige Fälle werden dem Radiologen zur abschließenden klinischen Entscheidung vorgelegt. Dieses Prinzip entspricht dem in industriellen Anwendungen etablierten Modell der aufgabenspezifischen Arbeitsteilung zwischen System und Mensch. Die quantitativen Auswirkungen dieses Ansatzes werden in Abschnitt 4.2 dargelegt.

4 Messbarkeit des Nutzens

4.1 Metriken zur Leistungsbewertung

Für die Bewertung KI-gestützter Bildanalyse sind standardisierte Klassifikationsmetriken etabliert, die im Sinne der SMART-Kriterien eingesetzt werden. Die vier zentralen Messgrößen sind:

- **Sensitivität (Recall):** Anteil der korrekt erkannten positiven Fälle. In der medizinischen Diagnostik ist eine hohe Sensitivität besonders relevant, da übersehene Befunde unmittelbare klinische Konsequenzen haben können.
- **Spezifität:** Anteil der korrekt erkannten negativen Fälle. Falsch positive Befunde erzeugen unnötige Folgeuntersuchungen.
- **F1-Score:** Harmonisches Mittel aus Precision und Recall, besonders relevant bei unausgewogener Klassenverteilung – etwa bei seltenen Krankheitsbildern.
- **AUC-ROC:** Fläche unter der Receiver-Operating-Characteristic-Kurve; klassenunabhängiges Gesamtmaß der Klassifikationsleistung, unabhängig vom gewählten Entscheidungsschwellenwert.

Diese Metriken gelten für industrielle und medizinische KI-Systeme gleichermaßen und unterstreichen die methodische Konvergenz beider Domänen.

4.2 KI im Vergleich zum Menschen

Der Standardbenchmark in der medizinischen KI-Forschung ist der direkte Vergleich zwischen KI-System und menschlichen Fachärzten auf einem gemeinsamen, verblindeten Testdatensatz. Tabelle 2 fasst aktuelle Ergebnisse aus der Literatur zusammen:

Tabelle 2: Leistungsvergleich KI vs. Radiologen in ausgewählten Studien

Anwendung	Sensitivität	Spezifität	Einordnung
Pneumonie (Röntgen)	88 %	90 %	vergleichbar mit Radiologen
Lungenkarzinom (Röntgen)	85 %	88 %	vergleichbar mit Radiologen
Krebsdiagnose (KI-assist.)	79 %	87 %	besser als ohne Unterstützung
Brustkrebsscreening	× 1,12	≈ 1,00	+12 % Sens., –44 % Aufwand

Quelle: [2], [11]

Die Ergebnisse zeigen konsistent: Der Einsatz von KI als ergänzender zweiter Leser erhöht die Sensitivität bei minimalem Spezifitätsverlust. Der Nutzenzuwachs entsteht nicht durch

Substitution des Radiologen, sondern durch Kombination: Das System reduziert den Befundungsaufwand und markiert auffällige Regionen; die abschließende klinische Entscheidung verbleibt beim Arzt [5].

5 Datensouveränität und Systemarchitektur

5.1 Rechtliche Anforderungen im Gesundheitswesen

Medizinische Bilddaten zählen nach Artikel 9 der Datenschutz-Grundverordnung (DSGVO) zu den besonderen Kategorien personenbezogener Daten. Ihre Verarbeitung erfordert eine explizite Rechtsgrundlage sowie organisatorische und technische Schutzmaßnahmen [12]. Ergänzend klassifiziert der EU AI Act – seit August 2024 in Kraft – KI-gestützte Diagnosetools in Geräten der Klasse IIb (z. B. Röntgen- oder CT-Systeme) als Hochrisiko-KI-Systeme [4]. Hersteller und Betreiber müssen bis August 2026 vollständige Konformität nachweisen, einschließlich technischer Dokumentation, Transparenzanforderungen und Risikoklassifikation. Die Wahl der Systemarchitektur ist damit zugleich eine regulatorische Entscheidung.

5.2 Cloud vs. On-Premise

Kommerzielle Cloud-Infrastruktur bietet Vorteile hinsichtlich Rechenkapazität und Skalierbarkeit. Jedoch ist eine geografisch „EU-Region“ bei Anbietern wie AWS, Azure oder Google Cloud keine ausreichende Garantie für Datensouveränität: Der US CLOUD Act verpflichtet US-amerikanische Unternehmen, behördlichen Zugriffsanfragen auch aus europäischen Rechenzentren nachzukommen [12]. Ein faktischer Datentransfer in Drittstaaten ist damit möglich – und mit den Anforderungen des Artikel 9 DSGVO nur schwer vereinbar. On-Premise-Architekturen schließen dieses Risiko strukturell aus: Patientendaten verbleiben vollständig innerhalb der Einrichtung und die Nachweispflichten der DSGVO sind leichter erfüllbar.

5.3 Federated Learning als datenschutzkonformer Lernverbund

KI-Modelle profitieren von größeren Trainingsdatensätzen – eine zentrale Aggregation von Patientendaten über Einrichtungsgrenzen hinweg ist jedoch datenschutzrechtlich nicht zulässig. Federated Learning adressiert diesen Zielkonflikt: Jede Einrichtung trainiert ein lokales Modell auf eigenen Daten; lediglich die aggregierten Modellgewichte werden geteilt. Rohdaten verbleiben vollständig innerhalb der jeweiligen Institution [3]. Ergänzende Techniken wie Differential Privacy – durch statistisches Rauschen in den Gradienten – und Secure Multi-Party Computation stärken den Datenschutz weiter. Aktuelle Forschungsergebnisse belegen, dass

Federated-Learning-Modelle bei ausreichend großem Klinikverbund eine mit zentral trainierten Modellen vergleichbare Qualität erreichen [13].

6 Fazit und Ausblick

6.1 Zusammenfassung

Der vorliegende Artikel hat gezeigt, dass das Gesundheitswesen bei der Einführung KI-gestützter Bildanalyse auf etablierte Methoden und Systemarchitekturen der industriellen Qualitätskontrolle zurückgreifen kann. Drei Kernaussagen lassen sich festhalten:

1. **Methodischer Transfer ist empirisch belegt.** CNN-Architekturen und Transfer Learning erzielen auf medizinischen Bilddaten radiologische Befundqualität; CheXNet übertrifft den Radiologen-Durchschnitt statistisch signifikant [1].
2. **Nutzen ist quantitativ messbar.** Der kombinierte Einsatz von KI und Radiologe reduziert den Befundungsaufwand um bis zu 44 % [2] und senkt das Fehlerrisiko bei erhöhter Arbeitslast [7].
3. **Datenschutzkonforme Architektur ist verfügbar.** Federated Learning mit Differential Privacy sowie On-Premise-Infrastrukturen erfüllen die Anforderungen von DSGVO und EU AI Act [3], [4].

6.2 Ausblick

Drei Entwicklungen werden die weitere Konvergenz beider Domänen prägen: Multimodale Modelle, die Bilddaten mit klinischen Texten und Labordaten verbinden; die regulatorische Reife durch den EU AI Act, der einheitliche Qualitätsstandards für diagnostische KI-Systeme schafft [4]; sowie Federated Learning als Standard für datensouveränes, standortübergreifendes Modelltraining in Klinikverbünden [13]. Zusammenfassend zeigen die untersuchten Verfahren und Architekturen, dass der Transfer industrieller KI-Bildanalyse in das Gesundheitswesen methodisch fundiert und regulatorisch umsetzbar ist.

Literaturverzeichnis

- [1] P. Rajpurkar u. a., "CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning," *arXiv preprint arXiv:1711.05225*, 2017. besucht am 5. Mai 2026. Adresse: <https://arxiv.org/abs/1711.05225>
- [2] "Artificial intelligence in breast cancer screening: A systematic review and meta-analysis of integration strategies," *European Journal of Cancer*, 2025. besucht am 19. Mai 2026. Adresse: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC12818982/>
- [3] M. Adnan, S. Kalra, J. C. Cresswell, G. W. Taylor und H. R. Tizhoosh, "Federated learning and differential privacy for medical image analysis," *Scientific Reports*, Jg. 12, Nr. 1, S. 1953, 2022. DOI: 10.1038/s41598-022-05539-7 besucht am 5. Mai 2026. Adresse: <https://www.nature.com/articles/s41598-022-05539-7>
- [4] Johner Institut. "Was der AI Act für Medizinprodukte- und IVD-Hersteller bedeutet," besucht am 16. Mai 2026. Adresse: <https://www.johner-institut.de/blog/regulatory-affairs/ai-act-eu-ki-verordnung/>
- [5] "Impact of human and artificial intelligence collaboration on workload reduction in medical image interpretation," *npj Digital Medicine*, 2024. besucht am 19. Mai 2026. Adresse: <https://www.nature.com/articles/s41746-024-01328-w>
- [6] Statista. "Anzahl von Radiologen in Deutschland nach ärztlichen Tätigkeitsbereichen," besucht am 17. Mai 2026. Adresse: <https://de.statista.com/statistik/daten/studie/276851/umfrage/anzahl-von-radiologen-in-deutschland-nach-aerztlichen-taetigkeitsbereichen/>
- [7] "Work overload and diagnostic errors in radiology," *European Journal of Radiology*, 2023. DOI: 10.1016/j.ejrad.2023.111145 besucht am 19. Mai 2026. Adresse: <https://www.sciencedirect.com/science/article/pii/S0720048X23003467>
- [8] American College of Radiology. "Burnout Fueling Workforce Woes," besucht am 17. Mai 2026. Adresse: <https://www.acr.org/Clinical-Resources/Publications-and-Research/ACR-Bulletin/Burnout-Fueling-Workforce-Woes>
- [9] "Deep Transfer Learning Using Real-World Image Features for Medical Image Classification, with a Case Study on Pneumonia X-ray Images," *Bioengineering*, 2024. DOI: 10.3390/bioengineering11040406 besucht am 19. Mai 2026. Adresse: <https://www.mdpi.com/2306-5354/11/4/406>
- [10] Yang u. a., "Application of Artificial Intelligence in Medical Imaging: Current Status and Future Directions," *iRADIOLOGY*, 2025. DOI: 10.1002/ird3.70008 besucht am 5. Mai 2026. Adresse: <https://onlinelibrary.wiley.com/doi/full/10.1002/ird3.70008>
- [11] "Diagnostic accuracy of artificial intelligence in chest radiography for pneumonia and lung cancer: A meta-analysis," *Clinical Imaging*, 2025. besucht am 19. Mai 2026. Adresse: <https://www.sciencedirect.com/science/article/pii/S2352047725000681>
- [12] Questa AI. "Navigating Medical GDPR in the Age of AI," besucht am 5. Mai 2026. Adresse: <https://www.questa-ai.com/privacy-cafe/navigating-medical-gdpr-in-the-age-of-ai>
- [13] "Advancements and challenges of federated learning in medical imaging: a systematic literature review," *Artificial Intelligence Review*, 2025. DOI: 10.1007/s10462-025-11489-z besucht am 16. Mai 2026. Adresse: <https://link.springer.com/article/10.1007/s10462-025-11489-z>

Eidesstattliche Erklärung

Hiermit versichere ich, die vorliegende Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt sowie die Zitate deutlich kenntlich gemacht zu haben.

Ich erkläre weiterhin, dass die vorliegende Arbeit in gleicher oder ähnlicher Form noch nicht im Rahmen eines anderen Prüfungsverfahrens eingereicht wurde.

Bad Hersfeld, den 19. Mai 2026

Luca Michael Schmidt